Desarrollo de un modelo de Regresión para predecir el número de casos confirmados de personas con COVID-19

Autor: Bryam David Vega Moreno
Maestro: Diego Quisi
Materia: Simulación
Universidad: Universidad Politécnica Salesiana
Carrera: Ciencias de la computación

Introducción

Actualmente, el covid se ha vuelto uno de los virus más trascendentales a nivel mundial, perjudicando económicamente a los paises, ademas de ello afecto en gran medida a los sistemas de salud que no estaban preparados para un virus como este. En nuestro específico, en Ecuador se ha desatado una creciente ola de contagios desde que inicio el virus, en donde hospitales estan al máximo de su capacidad y la mayoria de ellos no pueden atender a más personas. En este ocasión proponemos un modelo de regresión que nos permite predecir el número de personas que existiran en un determiado día, con la finalidad de poder tener un número cercano para estar preparados para lo que pueda pasar.

Desarrollo del modelo de regresión

Librerias a importar

Librerias para la lectura y el análisis de datos

```
In [175]: import pandas as pd
          import numpy as np

          from datetime import datetime, timedelta
```

Librerías para realizar procesos de transformación y división de datos

```
In [2]: from sklearn.model_selection import train_test_split
```

Librerias para realizar el proceso de regresión

```
In [3]: from sklearn.linear_model import LinearRegression
        from sklearn.pipeline import Pipeline
        from sklearn.preprocessing import PolynomialFeatures
```

Librerias para realizar las gráficas

```
In [4]: import altair as alt
        import matplotlib.pyplot as plt
```

Dataset

Para este análisis hemos preparado un dataset denominado **covid.csv** el cual es un dataset que tuvo un proceso de transformación mediante otros csv y se concentro la información para tener los datos de nuestro país que en este caso es Ecuador. El dataset contiene la siguiente información:

- **date:** Fecha en la que se obtiene los datos
- **death:** Número de personas fallecidas por el virus
- **confirmed:** Número de personas con el virus
- **recovered:** Número de personas recuperadas con el virus
- **day:** Número del dïa de la pandemia a partir del 1/01/2020

```
In [5]: df = pd.read_csv('./in/covid.csv')
        df.sample(5)
```

Out[5]:

	date	confirmed	deaths	recovered	day
252	2020-11-08	174907	12830	154956	312
202	2020-09-19	125620	11084	97063	262
140	2020-07-19	74013	5313	31901	200
291	2020-12-17	204249	13932	177951	351
23	2020-03-24	1082	27	3	83

```
In [6]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 409 entries, 0 to 408
Data columns (total 5 columns):
 #   Column     Non-Null Count  Dtype 
---  ------     --------------  ----- 
 0   date       409 non-null    object
 1   confirmed  409 non-null    int64 
 2   deaths     409 non-null    int64 
 3   recovered  409 non-null    int64 
 4   day        409 non-null    int64 
dtypes: int64(4), object(1)
memory usage: 16.1+ KB
```

Convertir datos para realizar un análisis exploratorio

Un paso muy importante para realizar los modelos es realizar un análisis con el fin de ver como se esta comportando la data, en esta ocasión procedemos a hacer un proceso de transformación rápido para poder trabajar con el tipo de datos correctos

```
In [7]: df_copy = df.copy(deep=True)
        df_copy = df_copy.convert_dtypes()
        df_copy['date'] = pd.to_datetime(df_copy['date'])
```

```
In [8]: df_copy.sample(5)
```

Out[8]:

	date	confirmed	deaths	recovered	day
253	2020-11-09	175269	12839	154956	313
33	2020-04-03	3368	145	65	93
281	2020-12-07	198244	13780	174188	341
81	2020-05-21	35306	2939	3557	141
87	2020-05-27	38103	3275	18425	147

```
In [9]: df_copy.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 409 entries, 0 to 408
Data columns (total 5 columns):
 #   Column     Non-Null Count  Dtype         
---  ------     --------------  -----         
 0   date       409 non-null    datetime64[ns]
 1   confirmed  409 non-null    Int64         
 2   deaths     409 non-null    Int64         
 3   recovered  409 non-null    Int64         
 4   day        409 non-null    Int64         
dtypes: Int64(4), datetime64[ns](1)
memory usage: 17.7 KB
```

Ya con estos datos transformados, procedemos a realizar un análisis exploratorio para ver como se estan comportando nuestros datos

---

Análisis exploratorio

```
In [10]: df_time = df_copy.set_index(['date'])
         df_time.drop('day',axis=1,inplace=True)
```

Como se comportan los datos en corte de cada mes

```
In [11]: df_time=df_time.resample('M').sum()
```

```
In [12]: df_time
```

Out[12]:

	confirmed	deaths	recovered
date			
2020-03-31	16469	423	84
2020-04-30	321161	12586	23439
2020-05-31	1029314	76863	210913
2020-06-30	1429745	118831	702114
2020-07-31	2217004	160481	978383
2020-08-31	3121790	189640	2521381
2020-09-30	3678159	304684	3008490
2020-10-31	4714534	379203	4009025
2020-11-30	5411330	390757	4740172
2020-12-31	6306084	430061	5504187
2021-01-31	7125483	445664	6083704
2021-02-28	7472445	428747	6333926
2021-03-31	9480656	505563	8151264
2021-04-30	4416015	222210	3756482

Personas que estan en tratamiento

```
In [13]: df_treatment = df_time['confirmed']-df_time['deaths']-df_time['recovered']
```

```
In [14]: df_treatment
```

```
Out[14]: date
         2020-03-31      15962
         2020-04-30     285136
         2020-05-31     741538
         2020-06-30     608800
         2020-07-31    1078140
         2020-08-31     410769
         2020-09-30     364985
         2020-10-31     326306
         2020-11-30     280401
         2020-12-31     371836
         2021-01-31     596115
         2021-02-28     709772
         2021-03-31     823829
         2021-04-30     437323
         Freq: M, dtype: Int64
```

Número de contagios, muetras, recuperaciones se da entre meses

```
In [15]: df_diff = df_time.diff()
```

```
In [16]: df_diff=df_diff.fillna(df_time.head(1).to_dict())
```

```
In [17]: df_diff
```

Out[17]:

	confirmed	deaths	recovered
date			
2020-03-31	16469	423	84
2020-04-30	304692	12163	23355
2020-05-31	708153	64277	187474
2020-06-30	400431	41968	491201
2020-07-31	787259	41650	276269
2020-08-31	904786	29159	1542998
2020-09-30	556369	115044	487109
2020-10-31	1036375	74519	1000535
2020-11-30	696796	11554	731147
2020-12-31	894754	39304	764015
2021-01-31	819399	15603	579517
2021-02-28	346962	-16917	250222
2021-03-31	2008211	76816	1817338
2021-04-30	-5064641	-283353	-4394782

Promedio de contiagios,muertes,recuperados

```
In [18]: df_diff.mean()
```

```
Out[18]: confirmed    315429.642857
         deaths        15872.142857
         recovered    268320.142857
         dtype: float64
```

Gráficas

En esta gráfica estamos mostrante el comportamiento de los datos a lo largo del tiempo, como podemos apreciar, el número de confirmados recuperados tiene una tendencia paralela,es decir, a medida que se van confirmando casos, podriamos decir que una gran mayoria de ellas se recupera, mientras que el resto pueda estar en tratamiento o fallecido

```
In [20]: alt.Chart(df_time.reset_index().melt('date')).mark_line().encode(
             x='date',
             y='value',
             color='variable'
         ).interactive()
```

Out[20]:

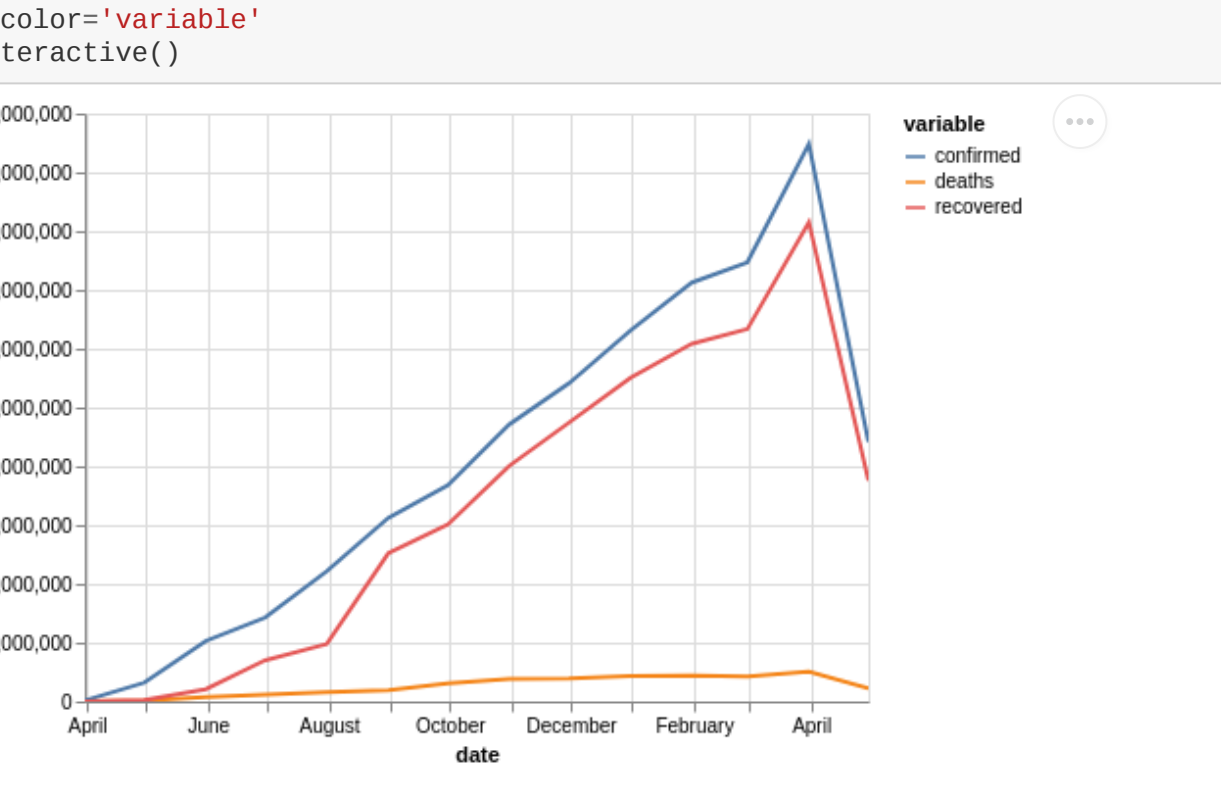

En esta gráfica mostramos el porcentaeje de personas recuperadas, fallecidas y en tratamiento, como podemos darnos cuente en la gráfica, podemos darnos cuenta que el número de personas con tratamiento va disminuyendo a medida que se va aumentando el número de personas recuperadas lo cual tiene sentido

```
In [21]: df_time['treatment'] = df_time['confirmed']-df_time['deaths']-df_time['recovered']
         df_time[['deaths','recovered','treatment']].T.iloc[:,:5].plot(figsize = (50,10),kind='pie',subplots=True)
```

```
Out[21]: array([<matplotlib.axes._subplots.AxesSubplot object at 0x7feb6df327f0>,
                <matplotlib.axes._subplots.AxesSubplot object at 0x7feb6df93130>,
                <matplotlib.axes._subplots.AxesSubplot object at 0x7feb6dfc2340>,
                <matplotlib.axes._subplots.AxesSubplot object at 0x7feb6dfed4f0>,
                <matplotlib.axes._subplots.AxesSubplot object at 0x7feb6e01a670>],
               dtype=object)
```

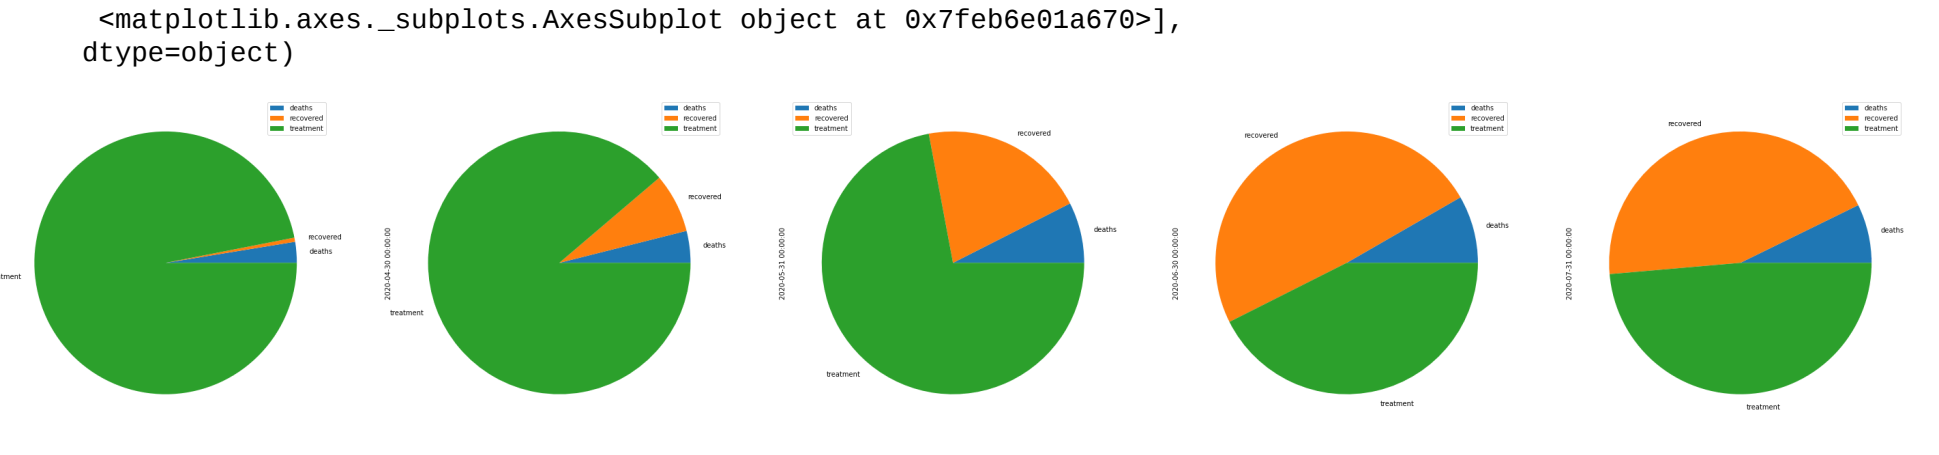

Un análisis muy bueno seria ver la velocidad con la que el virus se propaga a lo largo del tiempo, esto es importante para ver cual es su frecuencia de velocidad de propagación con el fin de entender como se esta compartando el virus en nuestro país. Como podemos ver en el histograma que presentamos a continuación la velocidad de propagación del virus es alta a medida que avanza el tiempo, lo interesante es darnos cuenta que es un virus muy contagioso por lo que su velocidad de propagación no ha bajado de los 0.90

```
In [22]: df_time['rate'] = 1 - df_time['deaths']/df_time['confirmed']
         df_time['rate'].plot(kind='hist',figsize=(10,7),bins=10,color='orange',alpha=0.5,title='Rate Virus',grid=True)
```

```
Out[22]: <matplotlib.axes._subplots.AxesSubplot at 0x7feb6eb04a00>
```

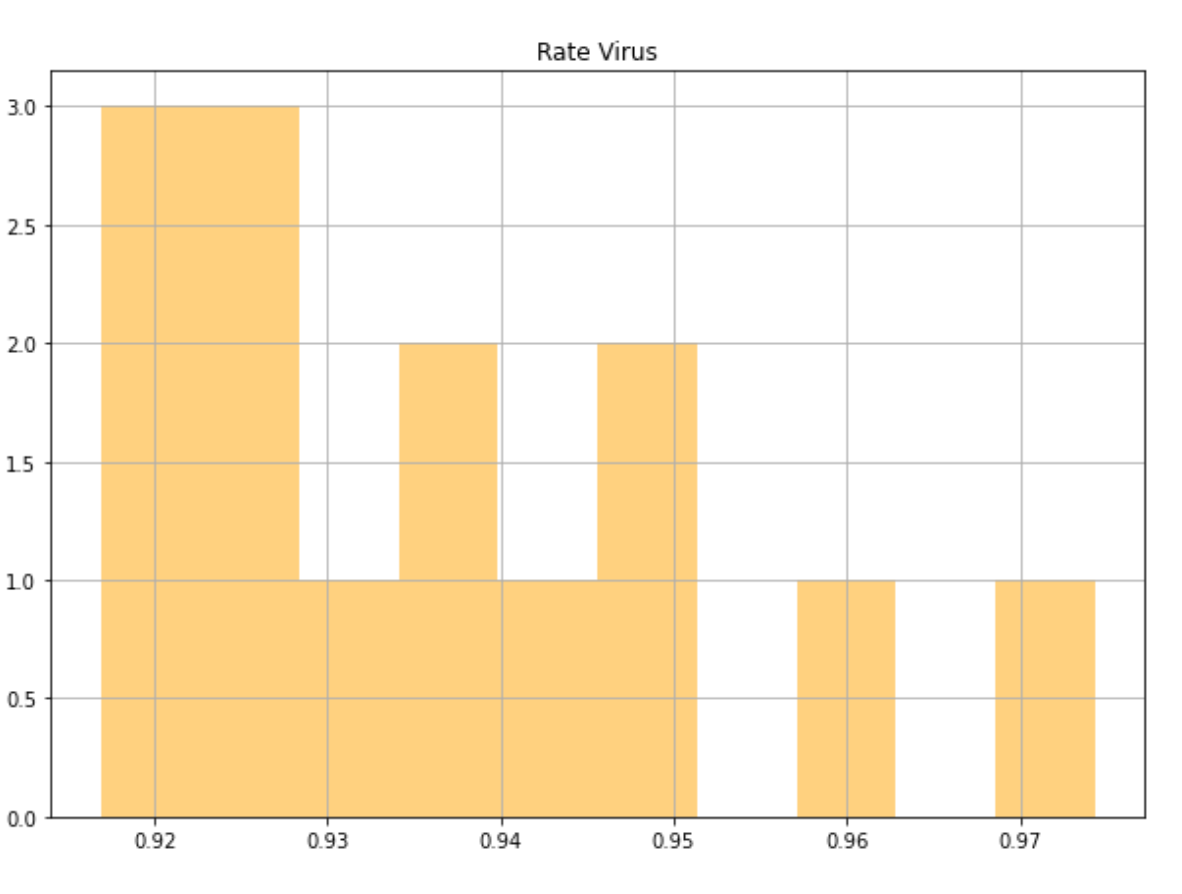

Una vez analizado los datos, procedemos a realizar la creación del modelo con el fin de poder escoger el mejor modelo para este tipo datos

---

Creación del modelo

Con el análisis de datos realizado, podemos darnos cuenta que nuestros datos tienen una tendencia a la alza, de manera lineal, por lo tanto un modelo de regresion seria ideal para poder estos datos. Lo primero que procedemos a hacer es obtener nuestro features y targets para poder hacer una división de datos en entrenamiento y test para poder entrenar a nuestro modelo y despues testearlo con los datos de test.

Selección de feautres y target

En este caso escogimos como features la columna **days** debido a que dicha columna juega el rol más improtante como hemos visto a lo largo del análisis, si bien en el análisis tratamos la columna date, no podemos utilizarla debido a ser un tipo de dato fecha, por lo que el día equivale a la fecha lo cual lo hace el feature más importate. Por otro lado escogimos la columna **confirmed** como nuestro target debido a que eso es lo que deseamos predecir, el número de contagios en un día a futuro

```
In [23]: features = df.iloc[:,4:5].values
         target = df.iloc[:,1:2].values
```

División de train y test

Una vez que ya tenemos nuestro conjunto de datos de entrada y salida, procedemos a dividir dichos datos en train y test a fin de realizar entreamiento con los datos de train y las pruebas con los datos de test, para ello hacemos uso de la libreria **train_test_split**. A continuación mostramos el código para realiarlo

```
In [24]: X_train, X_test, y_train, y_test = train_test_split(features, target, test_size=0.2)
```

Con estos datos dividos procedemos a realizar los modelos de regresión, a continuación procedemos a realizarlos.

Creación de un modelo de regesión

Como habiamos dicho, nuestros datos tienen una tendencia creciente y lineal, por lo que un modelo de regresión lineal es adecuado para este problema, para ello utilizamos el modelo **LinearRegression** para proceder a hacer nuestro entrenamiento y después las pruebas de nuestro modelo

```
In [25]: model_linear = LinearRegression()
         model_linear = model_linear.fit(X_train,y_train)
```

```
In [26]: print("Linear Score : ",model_linear.score(X_test,y_test))
```

```
Linear Score :  0.9859444494173236
```

Como podemos apreciar nuestro modelo lineal tiene una score de 0.98 lo cual es alto. Pero, seria mejor ver una gráfica de la misma con el fin de ver si nuestro modelo no tiene problema de overfitting

```
In [27]: data_linear=pd.DataFrame({'day':X_test.reshape(-1),'y':y_test.reshape(-1),'y_pred':model_linear.predict(X_test).resh
         ape(-1)})
         alt.Chart(data_linear.melt('day')).mark_line().encode(
             x='day',
             y='value',
             color='variable'
         ).properties(title='test vs predictions').interactive()
```

Out[27]:

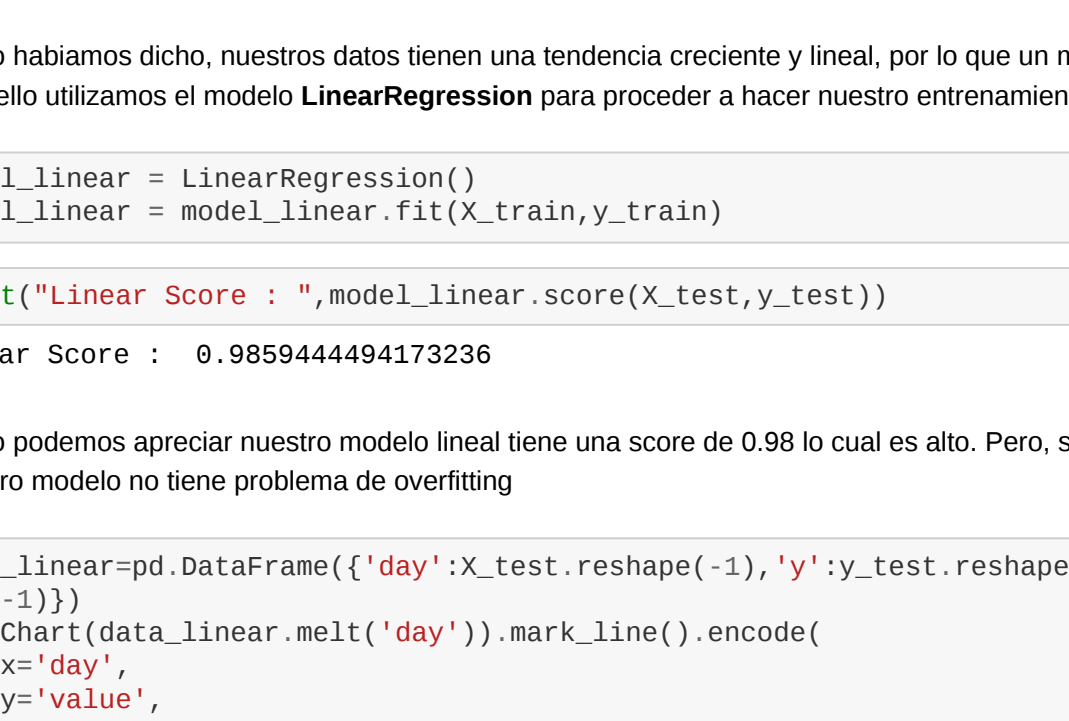

Como podemos apreciar, nuestro modelo no sufre de overfitting,aunque tenemos la linea la cual se ajusta a los datos correctamente, podemos notar algo interesante, si bien dijimos que tiene una tendencia creciente, podemos notar que nuestro datos tienen una forma polinomial, por lo que agregar un grado polinomial a nuestro modelo de regresión podria ayudar a mejorar nuestro modelo. Por lo que procedemos a realizarlo

```
In [28]: model_poly = Pipeline([('poly', PolynomialFeatures(degree=4)),
                                ('linear', LinearRegression(fit_intercept=True))])
         model_poly = model_poly.fit(X_train,y_train)
```

```
In [29]: print("Poly Score : ",model_poly.score(X_test,y_test))
```

```
Poly Score :  0.9990367771856549
```

Como podemos notar, nuestro modelo polinomial tiene un mejor score y esto es gracias al comportamiento de nuestros datos, procedemos a graficarlo para ver si no existe un problema de overfitting y mejoramos la curva

```
In [30]: data_poly=pd.DataFrame({'day':X_test.reshape(-1),'y':y_test.reshape(-1),'y_pred':model_poly.predict(X_test).reshape(
         -1)})
         alt.Chart(data_poly.melt('day')).mark_line().encode(
             x='day',
             y='value',
             color='variable'
         ).properties(title='test vs predictions').interactive()
```

Out[30]:

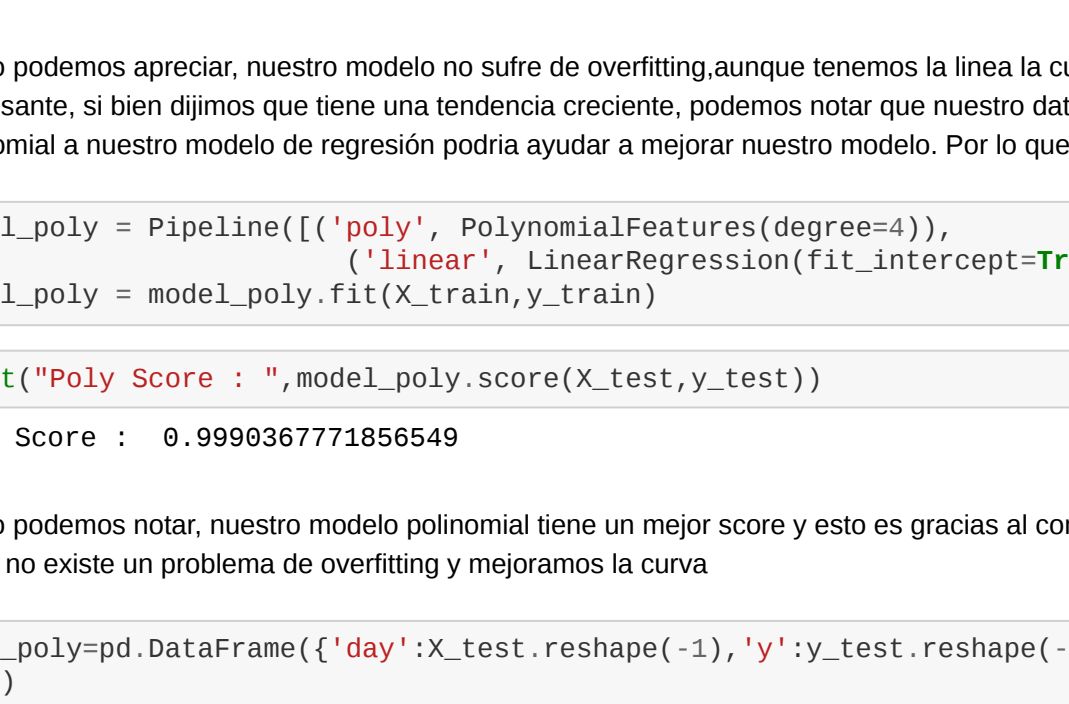

Podemos apreciar que realmente no existe problemas de overfitting y que nuestro modelo se ajusta a los datos, es interesante ver como el grado polinomial afecta en gran forma el ajuste a los datos, en este caso podemos decir que nuestro mejor modelo sera el **modelo polinomial**

Experimentos

Una vez analizado nuestros modelos analizamos como se comportaran nuestros modelos con nuevos datos. Vamos a predecir datos para los 10 siguientes días apartir del día 2020-04-14 con la finalidad de ver como se comportan nuestros modelos. El objetivo es hacer notar como el modelo lineal no es tan efectivo que el modelo polinomial como lo vimos en la anterior sección ya que el polinomial se ajusta mejor a nuestros datos

```
In [139]: datos = [i for i in range(469,480)]
          predicciones= {'{}'.format(i):[model_linear.predict(np.array(i).reshape(1,-1))[0][0],model_poly.predict(np.array(i).
          reshape(1,-1))[0][0]] for i in datos}
```

Una vez realiado las predicciones, realizamos una pequeña tabla, con la finalidad de poder ver de mejor manera las predicciones que obtuvimos y poder notar cual de los dos modelos se comporta mejor con nuevos datos. Procedemos a realizar el nuevo código

```
In [198]: inicio = datetime(2020,4,14)
          fin    = datetime(2020,4,24)
          lista_fechas = [(inicio + timedelta(days=d)).strftime("%Y-%m-%d")
                              for d in range((fin - inicio).days + 1)]
          df_predicciones = pd.DataFrame(predicciones_linear).T
          df_predicciones.columns = ['linear','polynomial']
          df_predicciones['linear']=df_predicciones['linear'].astype('int')
          df_predicciones['polynomial']=df_predicciones['polynomial'].astype('int')
          df_predicciones['date']=lista_fechas
```

```
In [199]: df_predicciones
```

Out[199]:

	linear	polynomial	date
469	311900	352314	2020-04-14
470	312746	354149	2020-04-15
471	313591	355999	2020-04-16
472	314436	357863	2020-04-17
473	315281	359742	2020-04-18
474	316126	361636	2020-04-19
475	316971	363545	2020-04-20
476	317816	365469	2020-04-21
477	318661	367409	2020-04-22
478	319507	369364	2020-04-23
479	320352	371335	2020-04-24

Como podemos ver en la tabla presentada, nos damos cuenta que el modelo lineal no se ajusta bien con nuevos datos y eso es debido a que no se ajusta a la curva de contagios como habiamos analizado anteriormente para poder realizar el modelo polinomial. Sin embargo, podemos darnos cuenta que el modelo polinomial se ajusta muy bien a los nuevos datos y predice nuevos contagios de manera creciente. Con una gráfica podemos analizar de mejor manera las predicciones realiadas

```
In [202]: alt.Chart(df_predicciones.melt('date')).mark_point().encode(
              x='date:N',
              y=alt.Y('value:Q',scale=alt.Scale(domain=(300000,400000))),
              color='variable:N'
          ).properties(title='linear vs polynomial').interactive()
```

Out[202]:

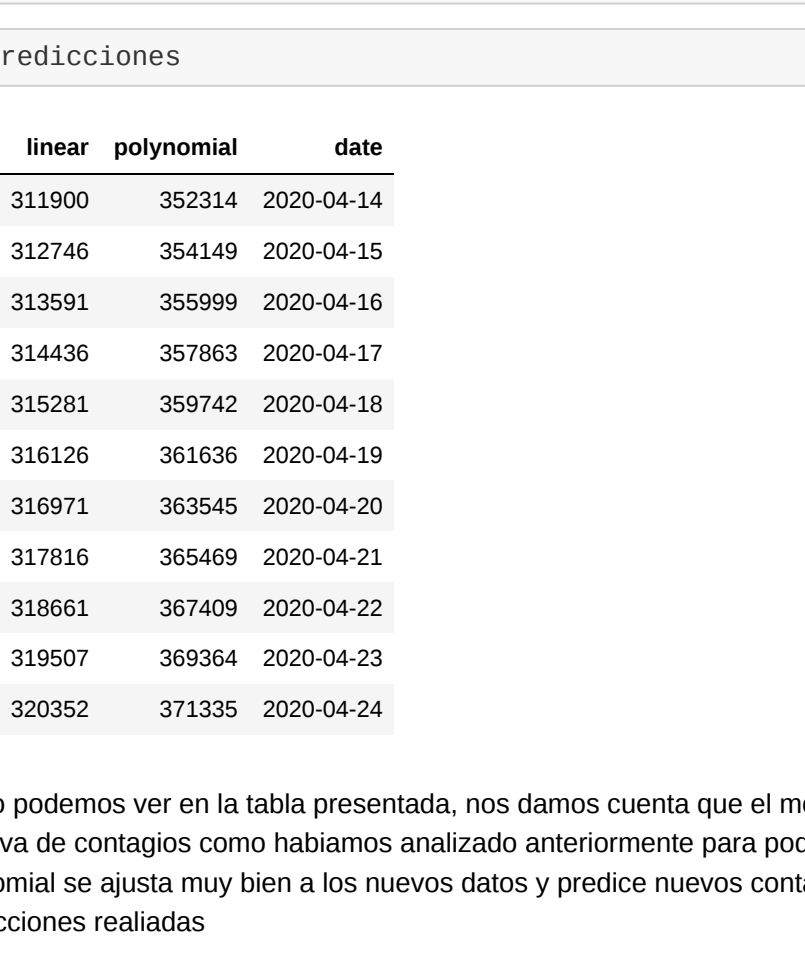

Como podemos apreciar en la gráfica presentada, podemos notar como el polinomial predice contagios más altos y que realmente tienen sentido con respecto a los datos que tenemos, mientras que por otro lado, el lienar predice contagios menores apartir de los datos que tenemos causando que sus predicciones no sean acertadas

Conclusiones

A lo largo de este informe hemos podido notar que realizar un análisis es un proceso importante para poder darnos cuenta como se estan comportando nuestro conjunto de datos, de la misma manera revisamos dos tipos de regresiones con el fin de ver cual es modelo que mejor se ajusta a nuestros datos y nos dimos cuenta que el **modelo polinomial** resulto ser el mejor modelo para este caso, **ojo** digo para este caso ya que no siempre sera el mejor, eso dependera de como se comportan los datos y del tratamiento que le demos a los mismos. Ademas de este informe, el cual presenta un análisis de todo lo realizado, se decidio tratar de automatizar dicho modelo, con la finaliadd de utilizarlo en producción cuando sea necesario, para ello creamos un entorno virtual con todas las librerias que se necesitan. Dicho programa automatiza el proceso de carga, transformación de datos, obtención de features, target, obtención del mejor modelo, ademas de ello exporta el modelo para poder ser utiliado en cualquier sitio web. A continuación dejo el comando que se requeire para poder ejecutar dicho programa:

```
python main.py in/covid.csv
```

Con ello ya no solamente pensamos en utilizar el modelo en cuadernos jupyter sino también utilizamos python de una manera más profesional con el fin de mejorar las skills del lenguaje.